

Los modelos (motores de IA) de OpenCode

Entiende qué hace funcionar a tus asistentes — sin necesidad de programar

JA Palazón Ferrando

2026-06-22

Contenidos

1	Introducción	2
2	Agentes vs. Modelos: la diferencia clave	2
2.1	Analogía rápida: el restaurante	2
2.2	¿Cómo se relacionan en la práctica?	3
3	El ecosistema de modelos de OpenCode	3
3.1	Los modelos de un vistazo	3
4	Modelo 1: «deepseek-v4-flash-free» — El modelo cloud siempre disponible	4
4.1	¿Qué es?	4
4.2	Analogía: La biblioteca pública	4
4.3	Características clave	4
4.4	¿Cuándo usarlo?	5
5	Modelo 2: «qwen-32b» / «big-pickle» — El motor local de alto rendimiento	5
5.1	¿Qué es?	5
5.2	Analogía: Tu taller personal de carpintería fina	5
5.3	¿Qué significa “32 mil millones de parámetros”?	5
5.4	Características clave	6
5.5	¿Cuándo usarlo?	6
5.6	El apodo: “Big Pickle” / “Pepinillo Grande”	6
6	Modelo 3: «mi-qwen» / «MiMo» — La infraestructura que lo sirve todo	6
6.1	¿Qué es?	6
6.2	Analogía: Tu propia central eléctrica	7
6.3	Características clave	7
6.4	¿Cuándo usarlo?	7
7	Tabla comparativa de modelos	8
7.1	El significado de los colores	8
8	¿Cuándo usar cada modelo? Guía por tarea	8
8.1	Según el tipo de contenido	8
8.2	Según la situación	9
9	Tabla de decisión rápida	10
9.1	Resumen en tres frases	10

10 Preguntas frecuentes 11
10.1 ¿Puedo cambiar de modelo mientras trabajo? 11
10.2 ¿Un modelo es mejor que otro? 11
10.3 ¿Puedo tener ambos modelos configurados? 11
10.4 ¿Qué modelo usa el agente explicador cuando no especifico nada? 11
10.5 ¿Necesito ser administrador del servidor para usar el modelo local? 11
10.6 ¿El modelo local consume muchos recursos? 11
11 Glosario de términos 12
12 Resumen final 12

1. Introducción

Si has usado OpenCode, seguro que ya conoces a los agentes: el explicador, el scribe, el general y el explore. Pero ¿alguna vez te has preguntado qué es lo que realmente piensa cuando haces una pregunta?

La respuesta son los modelos (o motores de lenguaje). Son el cerebro de la operación. Los agentes son como conductores especializados, pero el coche que conduce —el que tiene el motor— es el modelo.

Este documento está escrito para creadores de documentos que no programan. No necesitas saber de inteligencia artificial ni de servidores. Solo necesitas entender qué opciones tienes, cuándo conviene usar cada una y por qué.

Objetivo de este documento: Explicarte los modelos de OpenCode (deepseek-v4-flash-free, qwen-32b/big-pickle y mi-qwen/MiMo) como si fueran herramientas de un taller creativo.

i Nota

Nota importante: Este documento habla de modelos (los motores de IA). No lo confundas con los documentos anteriores que hablaban de agentes (los perfiles especializados como explicador o scribe). Ambos conceptos se complementan, pero son cosas distintas. Lo aclaramos en la siguiente sección.

2. Agentes vs. Modelos: la diferencia clave

Esta es la confusión más habitual entre quienes empiezan con OpenCode. Vamos a aclararla de una vez.

2.1. Analogía rápida: el restaurante

Imagina que OpenCode es un restaurante.

Table with 3 columns: Concepto, En el restaurante, En OpenCode. Row 1: Agente, El chef especializado: el pastelero, el parrillero, el salsero, El perfil que usas: explicador, scribe, general, explore.

Concepto	En el restaurante	En OpenCode
Modelo	El tipo de cocina: gas, inducción, leña, horno de barro	El motor de IA: deepseek-v4-flash-free, qwen-32b, mi-qwen

Un mismo chef (agente) puede cocinar en diferentes tipos de cocina (modelo). Y una misma cocina (modelo) puede ser usada por diferentes chefs (agentes).

Pregunta	Respuesta
¿El scribe es un modelo?	No. El scribe es un agente (un perfil de asistente).
¿deepseek-v4-flash-free es un agente?	No. Es un modelo (el motor que procesa el lenguaje).
¿Puedo usar el agente explicador con el modelo qwen-32b ?	Sí. Cada agente puede funcionar sobre diferentes modelos.



Consejo

Consejo: Cuando elijas un agente, decides **cómo** quieres que te ayude (explicando, redactando, investigando, explorando). Cuando elijas un modelo, decides **con qué motor** lo hará (rápido en la nube, o potente y privado en local).

2.2. ¿Cómo se relacionan en la práctica?

Cuando escribes un prompt en OpenCode, siempre usas ambas cosas sin darte cuenta:

```
scribe: Redacta una introducción para mi informe.
      ↑               ↑
      agente         modelo (seleccionado
                       en la configuración)
```

El agente le da la **instrucción de estilo** (redacta como un escriba profesional). El modelo le da la **capacidad de procesamiento** (entiende el lenguaje y genera texto).

3. El ecosistema de modelos de OpenCode

OpenCode puede funcionar con **tres modelos** distintos. Cada uno tiene sus propias características, ventajas y momentos ideales para usarlo.

3.1. Los modelos de un vistazo

#	Nom- bre técni- co	Alias / Apodo	Tipo	Dónde se ejecuta
1	deepseek- v4- flash- free	opencode/deepseek-v4- flash-free	Cloud (gratis)	Servidores de OpenCode
2	qwen- 32b	big-pickle / “pepinillo grande”	Local (privado)	Tu propio servidor
3	mi- qwen (pro- vee- dor)	MiMo (“Mi Modelo”)	Infraestruc- tura local	Tu propio servidor (192.168.0.127:4000)

Los modelos 2 y 3 están estrechamente relacionados: **qwen-32b** es el modelo en sí, y **mi-qwen** (apodado MiMo) es el **proveedor** que lo sirve. Pero a efectos prácticos, cuando usas **mi-qwen** estás usando el modelo **qwen-32b**.

4. Modelo 1: «deepseek-v4-flash-free» — El modelo cloud siempre disponible

4.1. ¿Qué es?

Es el modelo **por defecto de OpenCode**. Un motor de inteligencia artificial que se ejecuta en los servidores de OpenCode (en la nube). Está diseñado para ser **rápido, gratuito y fiable**.

4.2. Analogía: La biblioteca pública

Imagina que **deepseek-v4-flash-free** es como una **biblioteca pública municipal**:

- **Siempre abierta:** No necesitas pedir cita ni instalar nada. Abres OpenCode y ya está disponible.
- **Gratuita:** No pagas por usarla, entra dentro del servicio básico.
- **Bien surtida:** Tiene respuestas para la mayoría de preguntas y tareas cotidianas.
- **Rápida:** Encuentras lo que buscas sin largas esperas.

4.3. Características clave

Aspecto	Descripción
Velocidad	Alta. Responde en pocos segundos.
Privacidad	Media. Tus consultas viajan a servidores externos.
Disponibilidad	Siempre disponible mientras tengas internet.
Costo	Gratis.
Conexión requerida	Sí, necesitas internet.
Capacidad	Suficiente para la mayoría de tareas de documentación.

4.4. ¿Cuándo usarlo?

- **Siempre que empieces un proyecto nuevo.** Es el modelo por defecto por una razón: es rápido, fiable y no requiere configuración.
- **Cuando necesitas respuestas rápidas.** Para tareas cotidianas como redactar un párrafo, resumir una idea o estructurar una sección.
- **Cuando trabajas en equipo.** Como está en la nube, todos usan el mismo modelo y los resultados son consistentes.
- **Cuando no tienes acceso a tu servidor local.** Si estás fuera de la oficina o tu máquina local está apagada.



Consejo

Consejo: Usa `deepseek-v4-flash-free` como tu modelo predeterminado. Es como tener un asistente competente siempre disponible. Reserva los modelos locales para tareas que requieran más privacidad o potencia.

5. Modelo 2: «qwen-32b» / «big-pickle» — El motor local de alto rendimiento

5.1. ¿Qué es?

`qwen-32b` es un modelo de inteligencia artificial con **32 mil millones de parámetros** que se ejecuta en un servidor local (en tu propia infraestructura). Su alias es `big-pickle`, que cariñosamente se traduce como “**pepinillo grande**” o “**pepinote**”.

5.2. Analogía: Tu taller personal de carpintería fina

Si `deepseek-v4-flash-free` es la biblioteca pública, `qwen-32b` es tu **taller de carpintería en el garaje**:

- **Es tuyo:** Nadie más lo usa. No compartes recursos con otros usuarios.
- **Es potente:** Tienes maquinaria profesional (32 mil millones de parámetros) que permite trabajos más complejos.
- **Es privado:** Todo lo que hagas se queda en tu taller. Nadie mira tus proyectos.
- **Requiere mantenimiento:** Necesitas tener el servidor encendido y configurado.
- **Sin límites de uso:** Puedes usarlo todo lo que quieras, sin restricciones de cuota.

5.3. ¿Qué significa “32 mil millones de parámetros”?

Un **parámetro** es como una **conexión neuronal** en el cerebro del modelo. Cuantos más parámetros, más capacidad de comprensión y generación de lenguaje tiene.

Para que te hagas una idea:

Modelo	Parámetros	Analogía
<code>deepseek-v4-flash-free</code>	No especificado públicamente	Un asistente competente con formación universitaria
<code>qwen-32b</code>	32 mil millones	Un equipo de 32 especialistas trabajando en paralelo

Cuantos más parámetros, mejor puede el modelo: - Entender instrucciones complejas y matizadas. - Mantener coherencia en textos largos. - Capturar detalles y sutilezas del lenguaje. - Generar contenido más creativo y preciso.

5.4. Características clave

Aspecto	Descripción
Velocidad	Media-alta. Depende de la capacidad del servidor local.
Privacidad	Máxima. Todo queda en tu red local.
Disponibilidad	Depende de que el servidor local esté encendido.
Costo	Solo electricidad y mantenimiento del servidor. Sin cuotas por uso.
Conexión requerida	Red local (no necesitas internet externo).
Capacidad	Muy alta. Ideal para tareas complejas o documentos extensos.

5.5. ¿Cuándo usarlo?

- **Cuando trabajas con información sensible o confidencial.** Datos personales, secretos comerciales, documentos legales. Como todo se queda en tu servidor, no hay riesgo de filtración.
- **Cuando necesitas respuestas más profundas y matizadas.** Para análisis complejos, generación de documentos largos o tareas que requieren mucha coherencia.
- **Cuando tienes mucho trabajo y necesitas evitar límites de uso.** Los modelos cloud a veces tienen cuotas. El modelo local no tiene restricciones.
- **Cuando no tienes conexión a internet (pero sí red local).** Si estás en una instalación sin acceso externo, el modelo local sigue funcionando.
- **Para tareas que requieren máxima calidad.** Si un borrador con `deepseek` te parece correcto pero no excelente, prueba con `qwen-32b` para pulirlo.

Aviso

Advertencia: El modelo local requiere que el servidor esté encendido y accesible. Si viajas o trabajas desde casa sin conexión a la red de la oficina, no podrás usarlo (a menos que tengas el servidor contigo).

5.6. El apodo: “Big Pickle” / “Pepinillo Grande”

El alias `big-pickle` nace del juego de palabras con “Qwen” (que suena similar a “pickle” en inglés). Es un nombre cariñoso que usa el equipo para referirse a este modelo.

En español lo llamamos “**pepinillo grande**” o “**pepinote**”. No te extrañes si en las conversaciones del equipo escuchas frases como:

- “*Voy a ejecutar esto con el pepinillo grande para que quede más fino.*”
- “*El pepinote maneja mejor los documentos largos.*”
- “*¿Está encendido el pepinillo? Voy a mandarle un trabajo pesado.*”

6. Modelo 3: «mi-qwen» / «MiMo» — La infraestructura que lo sirve todo

6.1. ¿Qué es?

`mi-qwen` (abreviatura de “**Mi Qwen**”) es el **proveedor** que sirve el modelo `qwen-32b`. También se le conoce como **MiMo** (“**Mi Modelo**”).

Para entenderlo mejor:

Componente	Descripción	Analogía
qwen-32b / big-pickle	El modelo en sí (el motor de IA)	El motor del coche
mi-qwen / MiMo	El proveedor (el servicio que pone el modelo a tu disposición)	El concesionario y el taller que mantienen el coche

6.2. Analogía: Tu propia central eléctrica

Imagina que mi-qwen / MiMo es como tener tu **propia central eléctrica en casa**:

- **Independencia energética:** No dependes de la compañía eléctrica general. Generas tu propia electricidad.
- **Sin cortes:** No hay apagones por mantenimiento externo ni restricciones de horario.
- **A medida:** Puedes configurar la central para que funcione exactamente como necesitas.
- **Requiere inversión inicial:** Necesitas los paneles solares, las baterías, el inversor... pero luego la electricidad es prácticamente gratis.

En términos prácticos, cuando el equipo dice “estoy usando MiMo” o “voy a mi-qwen”, está diciendo que está usando el **modelo local** (qwen-32b) a través del **servicio local** (mi-qwen).

6.3. Características clave

Aspecto	Descripción
Dirección del servidor	192.168.0.127:4000 (en la red local)
Privacidad	Absoluta. No sale de tu red.
Control	Total. Tú decides cuándo actualizar, cómo configurar, etc.
Dependencia	Del servidor local. Si se apaga, no hay servicio.
Costo operativo	Electricidad + mantenimiento del hardware.
Límites de uso	Ninguno. Úsalo todo lo que quieras.

6.4. ¿Cuándo usarlo?

Técnicamente, mi-qwen y qwen-32b son inseparables: cuando activas uno, estás usando el otro. Pero a efectos prácticos:

- **Elige mi-qwen / MiMo** cuando quieras dejar claro que estás usando el **entorno local completo** (infraestructura + modelo).
- **Elige qwen-32b / big-pickle** cuando quieras referirte **específicamente al modelo** y sus capacidades.

En el uso diario, la mayoría del equipo dice simplemente “voy a usar el pepinillo” o “pásalo por MiMo” y todos entienden que se refieren al modelo local.

i Nota

Nota: mi-qwen significa “Mi Qwen” (mi versión del modelo Qwen). El apodo MiMo viene de “Mi Modelo”. Ambos reflejan el orgullo del equipo por tener un modelo propio, controlado y siempre disponible.

7. Tabla comparativa de modelos

Característica	deepseek-v4-flash-free	qwen-32b / big-pickle	mi-qwen / MiMo
Tipo	Cloud (nube)	Local (servidor propio)	Infraestructura local
Velocidad	Alta	Media-Alta	Media-Alta (depende del servidor)
Privacidad	Media (viaja a externos)	Máxima (todo local)	Máxima (todo local)
Disponibilidad	Siempre (con internet)	Depende del servidor	Depende del servidor
Conexión	Internet requerido	Red local solamente	Red local solamente
Costo	Gratuito	Electricidad + hardware	Electricidad + hardware
Límites de uso	Puede haber cuotas	Sin límites	Sin límites
Configuración	Ninguna (viene por defecto)	Requiere configuración inicial	Requiere configuración inicial
Capacidad	Buena para tareas generales	Excelente para tareas complejas	Excelente para tareas complejas
Ideal para	Uso diario, tareas rápidas	Trabajo profundo, datos sensibles	Trabajo profundo, datos sensibles

7.1. El significado de los colores

Color	Significado
Verde	Ventaja clara
Amarillo	Depende del contexto
Azul	Neutro, cumple sin destacar

8. ¿Cuándo usar cada modelo? Guía por tarea

No todos los modelos son igual de adecuados para todas las tareas. Esta tabla te ayuda a decidir rápidamente:

8.1. Según el tipo de contenido

Tarea	Modelo recomendado	¿Por qué?
Redactar un correo o mensaje corto	deepseek-v4-flash-free	Rápido, suficiente calidad, no requiere privacidad especial.
Escribir un informe estándar	deepseek-v4-flash-free	El modelo cloud maneja bien documentos de longitud media.
Documento extenso (tesis, manual, libro)	qwen-32b / big-pickle	Mayor coherencia en textos largos, más capacidad de mantener el hilo.
Documento con datos sensibles (nóminas, expedientes, secretos comerciales)	qwen-32b / big-pickle (o mi-qwen)	La privacidad es crítica. Todo debe quedar en local.
Análisis detallado de un concepto complejo	qwen-32b / big-pickle	Mayor profundidad y matiz en las respuestas.
Lluvia de ideas o brainstorming	deepseek-v4-flash-free	La velocidad permite iterar rápidamente.
Revisión y pulido final de un texto	qwen-32b / big-pickle	Mejor para detectar matices y mejorar la calidad del lenguaje.
Traducción de textos	Ambos funcionan bien	Si el texto es sensible, usa local. Si no, cloud es más rápido.
Resumir un artículo o capítulo	deepseek-v4-flash-free	Tarea rápida, el modelo cloud es más que suficiente.
Generar múltiples versiones de un mismo texto	deepseek-v4-flash-free	La velocidad te permite probar variantes rápidamente.

8.2. Según la situación

Situación	Modelo recomendado
Estás en una cafetería con wifi	deepseek-v4-flash-free (no tienes acceso al servidor local)
Estás en la oficina con el servidor encendido	Cualquiera, según la tarea
El servidor local está apagado o en mantenimiento	deepseek-v4-flash-free
Tienes una fecha de entrega ajustada	deepseek-v4-flash-free (rápido y fiable)
Necesitas la mejor calidad posible sin importar el tiempo	qwen-32b / big-pickle

Situación	Modelo recomendado
Estás trabajando con datos de pacientes o clientes	qwen-32b / big-pickle (obligatorio por privacidad)
No tienes internet pero sí red local	qwen-32b / big-pickle (vía mi-qwen)

⚠ Aviso

Advertencia de privacidad: Si trabajas con datos personales, información médica, secretos comerciales o cualquier contenido confidencial, usa siempre el modelo local (qwen-32b / mi-qwen). Los modelos cloud procesan tus consultas en servidores externos. Aunque la mayoría tienen políticas de privacidad, la única forma de garantizar que tus datos no salen de tu control es usar tu propio servidor.

9. Tabla de decisión rápida

¿No sabes qué modelo elegir? Responde estas preguntas en orden:

¿Tienes acceso al servidor local?

NO

SÍ

Usa
deepseek-v4-
flash-free
(cloud, rápido)

¿Son datos
confidenciales?

NO

SÍ

¿Tarea rápida
o superficial?
(local, seguro)

NO

SÍ

Usa
qwen-32b /
big-pickle
(local,
potente)

Usa deepseek-
v4-flash-free
(cloud, rápido)

9.1. Resumen en tres frases

Situación	Modelo
Quiero rapidez y no tengo datos sensibles	deepseek-v4-flash-free
Quiero máxima calidad o trabajo con datos privados	qwen-32b / big-pickle
Quiero referirme a todo el ecosistema local	mi-qwen / MiMo

10. Preguntas frecuentes

10.1. ¿Puedo cambiar de modelo mientras trabajo?

Sí. Puedes empezar una tarea con un modelo y, si no te convence el resultado, cambiar a otro y repetir la misma consulta. El agente (explicador, scribe, etc.) se mantiene, solo cambia el motor.

10.2. ¿Un modelo es mejor que otro?

No exactamente. Son **diferentes herramientas para diferentes necesidades**. `deepseek-v4-flash-free` es como un coche urbano: rápido, económico, perfecto para el día a día. `qwen-32b` es como un camión: más potente, más capacidad, pero requiere más mantenimiento. No dirías que un camión es “mejor” que un coche: cada uno tiene su uso.

10.3. ¿Puedo tener ambos modelos configurados?

Sí. OpenCode puede tener múltiples modelos configurados. Puedes alternar entre ellos según la tarea. Esta es la configuración más común y recomendada.

10.4. ¿Qué modelo usa el agente explicador cuando no especifico nada?

Por defecto, OpenCode usa `deepseek-v4-flash-free`. Es el modelo que viene preconfigurado. Si quieres usar otro, debes indicarlo explícitamente en la configuración.

10.5. ¿Necesito ser administrador del servidor para usar el modelo local?

Para la **configuración inicial**, alguien con conocimientos técnicos debe instalar y poner en marcha el servidor `mi-qwen`. Pero para el **uso diario**, cualquier persona puede seleccionar el modelo local en OpenCode sin necesidad de conocimientos técnicos.

10.6. ¿El modelo local consume muchos recursos?

Sí, `qwen-32b` requiere un servidor con buena tarjeta gráfica (GPU) y suficiente memoria RAM. No se ejecuta en un ordenador portátil normal. Por eso se aloja en un servidor dedicado (`192.168.0.127:4000`) al que todos los miembros del equipo se conectan por red local.



Consejo

Consejo: Si escuchas a alguien del equipo decir “*el pepinillo está pesado hoy*” o “*MiMo está reflexionando*”, significa que el modelo local está procesando una tarea compleja y tardará un poco más de lo normal. Es normal, dale su tiempo.

11. Glosario de términos

Para que no te pierdas cuando el equipo hable de estos temas:

Término	Significado
Agente	Perfil especializado de asistente (explicador , scribe , general , explore).
Modelo	Motor de IA que procesa el lenguaje (deepseek-v4-flash-free , qwen-32b).
Parámetros	“Conexiones neuronales” del modelo. A más parámetros, más capacidad.
Cloud	El modelo se ejecuta en servidores externos (en internet).
Local	El modelo se ejecuta en tu propia infraestructura (tu servidor).
Proveedor	El servicio que pone el modelo a disposición (mi-qwen es un proveedor).
big-pickle	Alias de qwen-32b (“pepinillo grande”).
MiMo	Alias de mi-qwen (“Mi Modelo”).
192.168.0.127:4000	Dirección del servidor local donde se ejecuta mi-qwen .

12. Resumen final

Modelo	Apodo	Cuándo usarlo
deepseek-v4-flash-free	—	Tareas cotidianas, rapidez, sin datos sensibles. Es tu opción por defecto.
qwen-32b	big-pickle / pepinillo grande	Trabajo profundo, documentos extensos, calidad superior, datos confidenciales.
mi-qwen / MiMo	Mi Modelo	Cuando quieras referirte a todo el ecosistema local (infraestructura + modelo).

Nota

Recuerda: Los **agentes** deciden **cómo** se hace el trabajo. Los **modelos** deciden **con qué motor** se hace. Ambos trabajan juntos para darte el mejor resultado posible. Ahora que conoces los modelos, puedes elegir con más criterio y aprovechar al máximo OpenCode.

Consejo

Consejo final: No te obsesiones con elegir el modelo “perfecto”. Para la mayoría de tareas diarias, **deepseek-v4-flash-free** funciona de maravilla. Cuando necesites más potencia o privacidad, ya sabes que el pepinillo grande está esperando en el servidor local.

Documento creado por el agente Scribe — 11 de junio de 2026

Curso completo disponible en: palazon.github.io/ocCursoAvanzado